概率论部分总结

更新： December 24, 2023

目录

1 基本概念和方法 **3**

1.1 试验和事件 3

1.2 频率和概率 4

1.3 等可能概型 (古典概型) 5

1.4 条件概率和衍生结论 6

1.5 独立性 7

2 随机变量的分布 **8**

2.1 基本定义 8

2.2 离散型随机变量 10

2.3 连续性随机变量 11

2.4 边缘分布 12

2.5 条件分布 13

2.6 随机变量的独立性 14

2.7 随机变量函数的分布 15

3 随机变量的数字特征 **18**

3.1 数学期望 18

3.2 方差 19

3.3 协方差 20

3.4 矩 21

4 重要分布 **22**

4.1 均匀分布 22

4.2 伯努利实验相关分布 23

4.3 泊松分布 23

4.4 正态分布 24

4.4.1 一维正态分布 24

4.4.2 二维正态分布 26

4.4.3 高维正态分布 27

4.5 Γ 分布、指数分布、χ^2 分布 27

4.6 常见分布的期望和方差 29

5 概率论的理论基础 **29**

5.1 大数定律 29

5.2 中心极限定理 30

5.3 中心极限定理和大数定律 31

1 基本概念和方法

1.1 试验和事件

随机试验 随机试验具有以下特点:

1. 可以在相同的条件下重复进行;
2. 每次试验的可能结果不止一个, 且能事先明确所有可能结果;
3. 每次试验之前不能确定哪一个结果会出现.

我们通过研究随机试验来研究随机现象.

样本空间 将随机试验 E 的所有可能结果组成的集合称为 E 的样本空间, 记为 S. 样本空间的元素, 即 E 的每个结果, 称为样本点.

随机事件 试验 E 的样本空间 S 的子集 A 被称为 E 的随机事件, 简称事件. 在每次试验中, 当且仅当该子集中的一个样本点出现时, 称该事件发生. 我们列出三个特殊事件:

- 基本事件: 由一个样本点组成的单点集;
- 必然事件: 样本空间 S 本身, 每次试验总是发生;
- 不可能事件: 空集 $\varnothing$, 每次试验总不发生.

随机事件的关系 事件是一个集合, 我们利用集合论处理事件间的关系. 设试验 E 的样本空间为 S, 而 $A, B \subset S$.

- $A \subset B$: 事件 B 包含 事件 A;
- $A = B$: 事件 A 与事件 B 相等;
- $A \cup B$: 事件 A 与事件 B 的和事件;
- $A \cap B$: 事件 A 与事件 B 的积事件, 简记为 AB;
- $A - B = \{x : x \in A, x \notin B\} = A \cap \overline{B}$: 事件 A 与事件 B 的差事件;
- $A \cap B = \varnothing$: 事件 A 与事件 B 互不相容 或者互斥; 事件 A 与事件 B 不能同时发生;
- $A \cup B = S$ 且 $A \cap B = \varnothing$: 事件 A 与事件 B 互为逆事件 或者对立事件; 事件 A, B 中有且仅有一个发生; A 的对立事件可以记为 $\overline{A}$.

注意: 对立事件一定是互斥的, 但是互斥事件不一定对立, 他们有可能均不发生.

随机事件的运算定律 设 $A, B, C \subset S$ 为事件, 则有

- 幂等率: $A \cup A = A$, $A \cap A = A$;
- 交换律: $A \cup B = B \cup A$, $A \cap B = B \cap A$;
- 结合律: $A \cup (B \cup C) = (A \cup B) \cup C$, $A \cap (B \cap C) = (A \cap B) \cap C$;
- 分配律: $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$, $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$;
- 德摩根率: $\overline{A \cup B} = \overline{A} \cap \overline{B}$, $\overline{A \cap B} = \overline{A} \cup \overline{B}$.

1.2 频率和概率

频率 在相同的条件下, 进行了 n 次试验, 在这 n 次试验中, 事件 A 发生的次数 n_A 称为事件 A 发生的频数. 比值 n_A/n 称为事件 A 发生的频率, 记作 $f_n(A)$, 它具有如下性质:

1. $0 \le f_n(A) \le 1$;
2. $f_n(S) = 1$;
3. 若 $A_1, A_2, \ldots, A_k \subset S$ 两两互不相容, 则

$$f_n(A_1 \cup A_2 \cup \cdots \cup A_k) = f_n(A_1) + f_n(A_2) + \cdots + f_n(A_k).$$

频率的稳定性: 从频率到概率 实验发现: 当 n 逐渐增大时, $f_n(A)$ 逐渐稳定于某个常数. 这种频率的稳定性 即通常所说的统计规律性. 为了便于理论研究, 我们从频率的性质和稳定性出发, 定义表征事件发生可能性大小的概率.

概率 设 E 是随机试验, S 是它的样本空间. 对于 E 的每一个事件 A 赋予一个实数, 记为 $P(A)$, 称为事件 A 的概率, 要求函数 $P: 2^S \to \mathbb{R}$ 满足下列条件:

1. 非负性: $\forall A \subset S$, $P(A) \ge 0$;
2. 规范性: $P(S) = 1$;
3. 可列可加性: $\forall A_i A_j = \varnothing, i \ne j$, 有

$$P(A_1 \cup A_2 \cup \cdots) = P(A_1) + P(A_2) + \cdots$$

概率的性质 从概率的三个条件出发, 可以得到如下概率的性质:

- $P(\varnothing) = 0$ 但是 $P(A) = 0 \not\Rightarrow A = \varnothing$.

- $\forall A_i A_j = \varnothing, i \neq j$,

$$P(A_1 \cup A_2 \cup \cdots \cup A_n) = P(A_1) + P(A_2) + \cdots + P(A_n).$$

  由此可以推出: $\forall A \subset S$, $P(\overline{A}) = 1 - P(A)$.

- 若 $A \subset B$, 则

$$P(B - A) = P(B) - P(A), \quad P(B) \geq P(A).$$

  由此可以推出: $\forall A \subset S$, $P(A) \leq 1$.

- $\forall A, B \subset S$, 有

$$P(A \cup B) = P(A) + P(B) - P(AB).$$

  可以将其推广到 3 个事件的情形: $\forall A, B, C \subset S$, 有

$$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(AB) - P(AC) - P(BC) + P(ABC).$$

  利用容斥原理可以进一步推广到 n 个事件的情形.

实际推断原理 人们在长期的实践中总结得到“概率很小的事件在一次实验中几乎是不发生的”, 称之为实际推断原理.

1.3 等可能概型 (古典概型)

定义 等可能概型是具有如下特点的一类随机试验:

1. 样本空间包含有限个元素;
2. 每个基本事件发生的可能性相同.

它是概率论发展初期的主要研究对象, 故又把它叫做古典概型. 具体来说, 试验的样本空间为 $S = \{e_1, e_2, \ldots, e_n\}$ 且

$$P(\{e_1\}) = P(\{e_2\}) = \cdots = P(\{e_n\}).$$

古典概型中的计算 根据定义, 由规范性和有限可加性可知:

$$P(\{e_i\}) = \frac{1}{n}, \quad i = 1, 2, \ldots, n$$

若事件 A 包含 k 个基本事件, 即 $A = \{e_{i_1}, e_{i_2}, \ldots, e_{i_k}\}$, 则

$$P(A) = \sum_{j=1}^{k} P(\{e_{i_j}\}) = \frac{k}{n} = \frac{|A|}{|S|}.$$

1.4 条件概率和衍生结论

直观定义 设 $A, B \subset S$ 且 $P(B) > 0$ 则称事件 A 在“事件 B 已发生”这一附加条件下的概率为在事件 B 已发生的条件下事件 A 的条件概率, 简称为 A 在 B 之下的条件概率, 记为 $P(A|B)$.

形式定义/计算 设 $A, B \subset S$ 且 $P(B) > 0$, 称

$$P(A|B) = \frac{P(AB)}{P(B)}$$

为事件 B 已发生的条件下事件 A 的条件概率.

性质: “条件概率也是概率” 我们可以验证条件概率 $P(\cdot|B)$ 符合概率定义的三个条件:

1. 非负性: $\forall A \subset S$, $P(A|B) \geq 0$;
2. 规范性: $P(S|B) = 1$;
3. 可列可加性: $\forall A_i A_j = \emptyset$,

$$P\left(\bigcup_{i=1}^{\infty} A_i \middle| B\right) = \sum_{i=1}^{\infty} P(A_i|B).$$

所以关于概率的重要结果也适用于条件概率.

乘法定理 以条件概率出发可知: 设 $P(B) > 0$, 则

$$P(AB) = P(A|B)P(B).$$

该定理容易推广到多个事件: 设 A, B, C 为事件, 且 $P(BC) > 0$, 则

$$P(ABC) = P(A|BC)P(BC) = P(A|BC)P(B|C)P(C)$$

此处 $P(BC) > 0 \implies P(C) \geq P(BC) > 0$. n 个事件的乘法公式也容易推得.

全概率公式 设 S 为试验 E 的样本空间, A 为 E 的事件, $B_1, \ldots, B_n$ 为 S 的划分 (参照集合的划分) 且 $P(B_i) > 0, i = 1, 2, \ldots, n$, 则

$$P(A) = P(A|B_1)P(B_1) + P(A|B_2)P(B_2) + \cdots + P(A|B_n)P(B_n).$$

其常用的形式包括: 若 $0 < P(B) < 1$, 则有

$$P(A) = P(A|B)P(B) + P(A|\overline{B})P(\overline{B}).$$

使用全概率公式计算复杂事件的概率可以遵循如下的思路:

- 把事件 A 看作过程结果, $B_1,\ldots,B_n$ 看作过程的若干原因;
- 根据历史资料/已知条件,
  - 每一原因发生的概率 (即 $P(B_i)$) 已知;
  - 每一原因对结果的影响程度 (即 $P(A|B_i)$) 已知;
- 全概率公式可以求: 结果发生的概率 (即 $P(A)$).

贝叶斯公式 设 S 为试验 E 的样本空间, A 为 E 的事件, $B_1,\ldots,B_n$ 为 S 的划分且 $P(A)>0, P(B_i)>0, i=1,2,\ldots,n$, 则

$$P(B_i|A)=\frac{P(A|B_i)P(B_i)}{P(A)}=\frac{P(A|B_i)P(B_i)}{\sum_{j=1}^{n}P(A|B_j)P(B_j)}\quad \forall i=1,2,\ldots,n$$

其常用的形式包括: 若 $0<P(B)<1$ 且 $P(A)>0$ 则有

$$P(B|A)=\frac{P(A|B)P(B)}{P(A|B)P(B)+P(A|\overline{B})P(\overline{B})}$$

使用贝叶斯公式可以遵循如下的思路:

- 把事件 A 看作过程结果, $B_1,\ldots,B_n$ 看作过程的若干原因;
- 根据历史资料/题设, 每一原因发生的概率 (即 $P(B_i)$) 已知, 每一原因对结果的影响程度 (即 $P(A|B_i)$) 已知;
- 如果已知事件 A 已经发生, 贝叶斯公式可以求: 此结果由第 i 个原因引起的概率 (即 $P(B_i|A)$).

其中 $P(B_i)$ 是以往数据分析得到的, 称为<u>先验概率</u>; $P(B_i|A)$ 是得到额外信息之后再重新加以修正的概率, 称为<u>后验概率</u>.

1.5 独立性

两个事件的独立性 设 $A,B\subset S$, 如果

$$P(AB)=P(A)P(B)$$

则称 A 与 B<u>相互独立</u>, 简称 A 与 B<u>独立</u>. 从定义可以得到如下的结论/性质:

- 若 $P(A)>0, P(B)>0$, 则 "A 与 B 相互独立" 与 "A 与 B 互不相容" 不能同时成立.
- 事件 A 与 B 独立, 且 $P(A)>0$, 则 $P(B|A)=P(B)$.

- 令 A 为任一事件, 则 (1) S 与 A 独立; (2) $\varnothing$ 与 A 独立.
- 若事件 A 与 B 相互独立, 则下列各对事件也相互独立: A 与 $\overline{B}$, $\overline{A}$ 与 B, $\overline{A}$ 与 $\overline{B}$.

n 个事件的独立性 设 $A_1, A_2, \ldots, A_n$ 是 $n \geq 2$ 个事件, 如果对所有的 $2 \leq m \leq n$, 有

$$P(A_{i_1} A_{i_2} \cdots A_{i_m}) = P(A_{i_1}) P(A_{i_2}) \cdots P(A_{i_m}), \forall 1 \leq i_1 < i_2 < \cdots < i_m \leq n$$

则称 $A_1, A_2, \ldots, A_n$相互独立; 即任意 2 个, 3 个, ... n 个事件的积事件概率等于各事件概率之积. 根据定义, 有类似的性质: 若 $A_1, A_2, \ldots, A_n$ 相互独立, 则

1. 其中任意 m 个事件也相互独立;
2. 其中任意多个事件换成对立事件所得的 n 个事件也互相独立.

针对独立事件, 有更加简便的加法公式: 若 $A_1, A_2, \ldots, A_n$ 相互独立, 则

$$P(A_1 \cup A_2 \cup \cdots \cup A_n) = 1 - P(\overline{A}_1) P(\overline{A}_2) \cdots P(\overline{A}_n).$$

特别地, 当 $P(A_i) = p$, 有

$$P(A_1 \cup A_2 \cup \cdots A_n) = 1 - (1-p)^n \xrightarrow{n \to \infty} 1$$

这说明: 小概率事件在一次试验中不发生 (实际推断原理), 但是多次重复后迟早要发生.

2 随机变量的分布

2.1 基本定义

随机变量 设随机试验的样本空间为 $S = \{e\}$. 定义在样本空间 S 上的实值单值函数 $X = X(e)$ 称为随机变量. 若 $L \subseteq \mathbb{R}$, 我们使用 $\{X \in L\}$ 表示事件 $A = \{e \in S : X(e) \in L\}$, 此时有

$$P\{X \in L\} = P(A) = P\{e \in S : X(e) \in L\}.$$

我们有时需要在同一个样本空间上定义多个随机变量: 设 E 是一个随机试验, 它的样本空间是 $S = \{e\}$, 设

$$X_i = X_i(e), \quad i = 1, 2, \ldots, n$$

是定义在 S 上的随机变量, 由它们构成的一个向量 $(X_1, X_2, \ldots, X_n)$, 叫做n 维随机向量 或 n 维随机变量. 我们重点研究 $n = 1$ 和 $n = 2$ 的情形, 即二维随机向量 或 二维随机变量.

分布函数 我们用分布函数完整描述随机变量: 对任意实数 $x_1, x_2, \ldots, x_n$, n 元函数

$$F(x_1, x_2, \ldots, x_n) = P\{X_1 \le x_1, X_2 \le x_2, \ldots, X_n \le x_n\}$$

称为 n 维随机变量 $(X_1, X_2, \ldots, X_n)$ 的分布函数; 当 $n \ge 2$ 时, 也称为随机变量 $X_1, X_2, \ldots, X_n$ 的联合分布函数. 分布函数是一个普通的函数, 我们可以利用数学分析的方法研究它来研究随机变量.

一维分布函数和区间概率 如果将一维随机变量 X 看成是数轴上的随机点坐标, 那么分布函数 $F(x)$ 表示 X 落在区间 $(-\infty, x]$ 上的概率. 已知 X 的分布函数, 我们可以知道 X 落在任一区间 $(x_1, x_2]$ 上的概率:

$$P\{x_1 < X \le x_2\} = P\{X \le x_2\} - P\{X \le x_1\} = F(x_2) - F(x_1).$$

此外, 对任意的 a, 我们有

$$P\{X = a\} = F(a+0) - F(a-0) = F(a) - F(a-0)$$

这允许我们计算各类区间的概率. 特别需要注意的是, 若分布函数 $F(x)$ 在 $x = a$ 处连续, 则 $P\{X = a\} = 0$. 此时, 端点不再重要: $P\{a \le X \le b\} = P\{a < X \le b\}$.

一维分布函数的性质 利用上面的联系, 可以给出分布函数 $F(x)$ 具有以下基本性质; 反过来, 满足这些性质的函数 $F(x)$ 也必是某个随机变量的分布函数.

1. 不减性: $x_1 < x_2 \implies F(x_2) - F(x_1) \ge 0$;
2. 规范性: $0 \le F(x) \le 1$, $F(-\infty) = 0$, $F(\infty) = 1$;
3. 右连续: $F(x+0) = F(x)$.

二维分布函数和区域概率 二维随机变量 (X, Y) 可看作平面 $\mathbb{R}^2$ 上的随机点, 那么 $F(x, y)$ 的值是 (X, Y) 落在以 (x, y) 为右上顶点的无穷矩形区域 $(-\infty, x] \times (-\infty, y]$ 内的概率. 随机点 (X, Y) 落在矩形区域 $(x_1, x_2] \times (y_1, y_2]$ 内的概率为:

$$P\{x_1 < X \le x_2, y_1 < Y \le y_2\} = F(x_2, y_2) - F(x_2, y_1) - F(x_1, y_2) + F(x_1, y_1)$$

二维分布函数的性质 二维随机变量分布函数具有如下基本性质; 反之，如果某一个二元函数具有这四条性质, 则它一定是某一个二维随机变量的分布函数.

1. 不减性: 对任意固定的 x 和 y, 有

$$x_2 > x_1 \implies F(x_2, y) \geq F(x_1, y)$$
$$y_2 > y_1 \implies F(x, y_2) \geq F(x, y_1)$$

2. 规范性: $0 \leq F(x, y) \leq 1$ 且对任意固定的 x 和 y, 有

$$F(-\infty, y) = 0, \quad F(x, -\infty) = 0, \quad F(-\infty, -\infty) = 0, \quad F(\infty, \infty) = 1$$

3. 右连续:

$$F(x+0, y) = F(x, y), \quad F(x, y+0) = F(x, y)$$

4. 非负性: 对 $x_1 < x_2, y_1 < y_2$, 有

$$F(x_2, y_2) - F(x_2, y_1) - F(x_1, y_2) + F(x_1, y_1) = P\{x_1 < X \leq x_2, y_1 < Y \leq y_2\} \geq 0$$

前三条性质是对一维分布函数的直接推广; 性质四与性质一描述类似的性质, 但是不能互相蕴含. 此外, 特别注意, 没有关于 $F(\infty, y)$ 和 $F(x, \infty)$ 的性质, 它们不一定等于 1.

2.2 离散型随机变量

一维离散型随机变量 如果随机变量 X 的取值是有限个或可列无穷个, 则称 X 为离散型随机变量. 设离散型随机变量 X 的所有可能取值为 x_k, $k = 1, 2, \ldots$, 则

$$P\{X = x_k\} = p_k, \qquad k = 1, 2, \ldots$$

称为离散型随机变量 X 的分布律. 分布律可以用表格来表示

X	x_1	x_2	$\cdots$
p_k	p_1	p_2	$\cdots$

由定义可知, 分布律具有如下的性质:

$$(1)\ p_k \geq 0, \qquad (2)\ \sum_{k=1}^{\infty} p_k = 1.$$

给出分布律, 分布函数可以如下求出:

$$F(x) = P\{X \leq x\} = \sum_{x_k \leq x} P\{X = x_k\} = \sum_{k: x_k \leq x} p_k$$

它是一个分段函数, 它在 $x = x_k, k = 1, 2, \ldots$ 处有跳跃, 跳跃值为 p_k.

二维离散型随机变量 如果二维随机变量 (X,Y) 全部可能取值是有限对或可列无限多对, 则 (X,Y) 是二维离散型随机变量. 令 X 的取值为 $x_1,x_2,\ldots$, Y 的取值为 $y_1,y_2,\ldots$ 则

$$p_{ij}=P\{X=x_i,Y=y_j\},\qquad i,j=1,2,\ldots$$

为二维离散型随机变量 (X,Y) 的分布律, 或称为随机变量 X 和 Y 的 联合分布律. 与一维离散型随机变量类似, 二维离散型随机变量也可以利用表格表示其联合分布律:

$Y\backslash X$	x_1	x_2	$\cdots$	x_i	$\cdots$
y_1	p_{11}	p_{21}	$\cdots$	p_{i1}	$\cdots$
y_2	p_{12}	p_{22}	$\cdots$	p_{i2}	$\cdots$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	
y_j	p_{1j}	p_{2j}	$\cdots$	p_{ij}	$\cdots$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	

由定义, 联合分布律具有如下性质:

$$(1)\ p_{ij}\geq 0,\qquad\qquad (2)\ \sum_{i=1}^{\infty}\sum_{j=1}^{\infty}p_{ij}=1.$$

给出联合分布律, 联合分布函数可以如下求出:

$$F(x,y)=\sum_{i:x_i\leq x}\sum_{j:y_j\leq y}p_{ij}.$$

2.3 连续性随机变量

一维连续型随机变量 如果对于随机变量 X 的分布函数 $F(x)$, 存在非负函数 $f(x)$, 使得对于任意实数 x, 有

$$F(x)=\int_{\infty}^{x}f(t)\mathrm{d}t$$

则称 X 为连续型随机变量, 其中函数 $f(x)$ 称为 X 的概率密度函数, 简称概率密度. 概率密度具有如下性质:

1. 非负性: $f(x)\geq 0$;
2. 规范性: $\int_{-\infty}^{\infty}f(x)\mathrm{d}x=1$; 介于曲线 $y=f(x)$ 与 x 轴之间的面积等于 1;
3. 对任意实数 $x_1\leq x_2$, 有

$$P\{x_1<X\leq x_2\}=F(x_2)-F(x_1)=\int_{x_1}^{x_2}f(x)\mathrm{d}x;$$

几何上看, X 落在区间 $(x_1,x_2]$ 的概率等于该区间上曲线 $y=f(x)$ 下曲边梯形的面积;

4. 若 $f(x)$ 在点 x 处连续, 则

$$F'(x) = f(x), \quad P\{x < X \le x + \Delta x\} = F(x + \Delta x) - F(x) \approx f(x)\Delta x$$

实际上, 满足性质 1、2 的必是某一随机变量的概率密度函数.

连续型随机变量的特点 概率密度函数给出的不是概率! 对连续型随机变量 X, 它取任一指定实数 x 的概率均为 0, 即

$$P\{X = x\} = 0$$

注意, 事件 $\{X = x\}$ 并非不可能事件, 所以, 若 $A = \varnothing$, 则 $P(A) = 0$; 但反之并不成立! 由此特点, 改变概率密度 $f(x)$ 在个别点的函数值不影响分布函数 $F(x)$ 的取值; 在计算连续型随机变量落在某一区间的概率时, 可以不必区分区间是开区间、闭区间、半开半闭区间.

二维连续型随机变量 对于二维随机变量 (X, Y) 的分布函数 $F(x, y)$, 如果存在非负函数 $f(x, y)$, 使得对于任意的 x, y 有:

$$F(x, y) = \int_{-\infty}^{y} \int_{-\infty}^{x} f(u, v)\mathrm{d}u\mathrm{d}v,$$

则称 (X, Y) 是二维连续型随机变量, 函数 $f(x, y)$ 称为二维随机变量 (X, Y) 的概率密度, 或称为 X 和 Y 的联合概率密度. 根据定义, 联合概率密度有如下的性质:

1. $f(x, y) \ge 0$;
2. $\displaystyle\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y)\mathrm{d}x\mathrm{d}y = F(\infty, \infty) = 1$; 几何上表示: 介于曲面和 xOy 的空间体积为 1;
3. 设 G 为平面上的区域, 则

$$P\{(X, Y) \in G\} = \iint_G f(x, y)\mathrm{d}x\mathrm{d}y$$

   几何上表示: $P\{(X, Y) \in G\}$ 的值等于以 G 为底, 以曲面 $z = f(x, y)$ 为顶的柱体体积.
4. 若 $f(x, y)$ 在 (x, y) 处连续, 则

$$\frac{\partial^2 F(x, y)}{\partial x \partial y} = f(x, y), \quad P\{x < X \le x + \Delta x, y < Y \le y + \Delta y\} \approx f(x, y)\Delta x\Delta y.$$

2.4 边缘分布

边缘分布函数 令二维随机变量 (X, Y) 具有分布函数 $F(x, y)$. 随机变量 X 和 Y 也具有各自的分布函数 $F_X(x), F_Y(y)$, 依次称为二维随机变量 (X, Y) 关于 X 和 Y 的边缘分布函数,

它们完全由联合分布函数 $F(x,y)$ 确定:

$$F_X(x) = P\{X \le x\} = P\{X \le x, Y < \infty\} = F(x,\infty)$$
$$F_Y(y) = P\{Y \le y\} = P\{X < \infty, Y \le y\} = F(\infty, y)$$

针对离散型和连续型随机变量, 我们分别给出边缘分布律 和边缘概率密度.

离散型: 边缘分布律 令离散型随机变量 (X,Y) 的联合分布律为

$$p_{ij} = P\{X = x_i, Y = y_j\},\ i,j = 1,2,\dots$$

其关于 X 和 Y 的边缘分布律 分别为

$$p_{i\cdot} = P\{X = x_i\} = \sum_{j=1}^{\infty} P\{X = x_i, Y = y_j\} = \sum_{j=1}^{\infty} p_{ij},$$
$$p_{\cdot j} = P\{Y = y_j\} = \sum_{i=1}^{\infty} P\{X = x_i, Y = y_j\} = \sum_{i=1}^{\infty} p_{ij}$$

利用联合分布律表格可以看出: $p_{i\cdot}$ 是所在列的概率之和, $p_{\cdot j}$ 是所在行的概率之和.

$Y\backslash X$	x_1	x_2	$\cdots$	x_i	$\cdots$	
y_1	p_{11}	p_{21}	$\cdots$	p_{i1}	$\cdots$	$p_{\cdot 1}$
y_2	p_{12}	p_{22}	$\cdots$	p_{i2}	$\cdots$	$p_{\cdot 2}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$
y_j	p_{1j}	p_{2j}	$\cdots$	p_{ij}	$\cdots$	$p_{\cdot j}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$
	$p_{1\cdot}$	$p_{2\cdot}$	$\cdots$	$p_{i\cdot}$	$\cdots$	

连续型: 边缘概率密度 令连续型随机变量 (X,Y) 的联合密度函数为 $f(x,y)$, 其关于 X 和 Y 的边缘概率密度 分别为

$$f_X(x) = \int_{-\infty}^{\infty} f(x,y)\mathrm{d}y, \quad f_Y(y) = \int_{-\infty}^{\infty} f(x,y)\mathrm{d}x$$

2.5 条件分布

离散型随机变量的条件概率分布 由边缘分布律和条件概率的定义, 我们研究条件概率分布. 设 (X,Y) 是二维离散型随机变量, 对于固定的 j, 若 $P\{Y = y_j\} > 0$, 则称

$$P\{X = x_i | Y = y_j\} = \frac{P\{X = x_i, Y = y_j\}}{P\{Y = y_j\}}, \quad i = 1,2,\dots$$

为 $Y=y_j$ 条件下随机变量 X 的条件分布律. 类似地, 由对称性, 可以定义 $X=x_i$ 条件下随机变量 Y 的条件分布律.

连续型随机变量的条件概率分布 对连续型随机变量 Y, 我们知道 $P\{Y=y_j\}=0$, 所以离散型随机变量的条件概率分布的定义无法直接迁移至连续型随机变量. 我们需要回到源头, 重新定义条件分布函数: 给定 y, 设对任意 $\Delta>0$, 有 $P\{y<Y\le y+\Delta\}>0$, 若对任意 x, 如下的极限存在

$$\lim_{\Delta\to 0^+} P\{X\le x|y<Y\le y+\Delta\}$$

则称其为在 $Y=y$ 的条件下 X 的条件分布函数, 记作 $P\{X\le x|Y=y\}$ 或者 $F_{X|Y}(x|y)$. 根据极限的定义, 当 Δ 很小时,

$$F\{X\le x|y<Y\le y+\Delta\}\approx F_{X|Y}(x|y).$$

连续型随机变量的条件概率密度 根据上述定义的条件分布函数, 我们给出条件概率密度: 设二维连续型随机变量 (X,Y) 的概率密度为 $f(x,y)$, 关于 Y 的边缘概率密度为 f_Y. 若对固定的 y, 有 $f_Y(y)\ge 0$, 则在 $Y=y$ 的条件下 X 的条件概率密度 为

$$f_{X|Y}(x|y)=\frac{f(x,y)}{f_Y(y)} \quad \text{且有} \quad F_{X|Y}(x|y)=\int_{-\infty}^{x} f_{X|Y}(u|y)\mathrm{d}u$$

观察连续型随机变量的条件概率密度定义:

$$f_{X|Y}(x|y)=\frac{f(x,y)}{f_Y(y)}=\frac{g(x)}{\displaystyle\int_{-\infty}^{\infty} g(x)\mathrm{d}x}$$

其中 $z=g(x)=f(x,y)$ 是空间曲面 $z=f(x,y)$ 与平面 $y=y$ 相交所得的空间曲线在 xOz 平面上的投影. 其正规化后, 正是 $Y=y$ 条件下 X 的条件概率密度的图像.

2.6 随机变量的独立性

两个随机变量的独立性 设 $F(x,y)$ 是二维随机变量 (X,Y) 的分布函数, $F_X(x)$ 和 $F_F(y)$ 是其边缘分布函数. 若

$$F(x,y)=F_X(x)\cdot F_Y(y) \quad \forall x,y\in\mathbb{R}$$

则称 X,Y 相互独立. 随机变量独立包含了无穷个事件独立的要求 (即对 $x,y\in\mathbb{R}$). 从定义可知, 相互独立的随机变量的联合分布由其边缘分布唯一确定; 一般情形下是不成立的. 针对离散型和连续型随机变量, 我们基于分布律和概率密度的定价定义:

- 设 (X,Y) 是二维离散型随机变量, 它们的取值分别为 $x_1,x_2,\ldots$ 和 $y_1,y_2,\ldots$, 若

$$P\{X=x_i,Y=y_i\}=P\{X=x_i\}P\{Y=y_j\},\quad \forall i,j$$

  则 X,Y 相互独立.
- 设 (X,Y) 是二维连续型随机变量, 其联合密度函数为 $f(x,y)$, 随机变量 X 和 Y 的边缘密度分别为 $f_X(x)$ 和 $f_Y(y)$, 若对几乎所有的 x,y 有

$$f(x,y)=f_X(x)f_Y(y)$$

  则 X,Y 相互独立. 此处"几乎所有"的含义是: 平面上除去"面积"为 0 的集合以外的所有; 实际上, 对所有连续点必须成立.

推广: n 维随机变量的独立性 设 n 维随机变量 $(X_1,X_2,\ldots,X_n)$ 的分布函数定义为

$$F(x_1,x_2,\ldots,x_n)=P\{X_1\le x_1,X_2\le x_2,\ldots,X_n\le x_n\},\quad \forall x_1,x_2,\ldots,x_n.$$

则 k 维边缘分布函数就随之确定 $(k\in[1,n))$; 例如, 我们有定义

$$F_{X_1,X_2}(x_1,x_2)=F(x_1,x_2,\infty,\ldots,\infty).$$

我们有如下两个关于独立性的定义:

- 若

$$F(x_1,x_2,\ldots,x_n)=F_{X_1}(x_1)\cdot F_{X_2}(x_2)\cdots F_{X_n}(x_n),\quad \forall x_1,x_2,\ldots,x_n$$

  则称 $X_1,X_2,\ldots,X_n$ 互相独立.
- 若

$$F(x_1,\ldots,x_i,x_{i+1},\ldots,x_n)=F_1(x_1,\ldots,x_i)\cdot F_2(x_{i+1},\ldots,x_n),\quad \forall x_1,x_2,\ldots,x_n$$

  其中 F_1,F_2 分别为随机变量 $(X_1,\ldots,X_i)$ 和 $(X_{i+1},\ldots,X_n)$ 的分布函数, 则称随机变量 $(X_1,\ldots,X_i)$ 和 $(X_{i+1},\ldots,X_n)$ 相互独立.

我们有如下的结论: 设随机变量 $(X_1,\ldots,X_m)$ 和 $(Y_1,\ldots,Y_n)$ 相互独立, 则 $X_i,i\in[1,m]$ 和 $Y_j,j\in[1,n]$ 相互独立. 若 f,g 是连续函数, 则 $f(X_1,\ldots,X_m)$ 和 $g(Y_1,\ldots,Y_n)$ 相互独立.

2.7 随机变量函数的分布

离散型随机变量的函数 已知离散型随机变量 $X\in\mathbb{X}$ 和分布律, 则随机变量 $Y=g(X)\in\mathbb{Y}=g(\mathbb{X})$, 且分布律为:

$$\forall y\in\mathbb{Y},\quad P\{Y=y\}=P\{X\in g^{-1}(y)\}=\sum_{x\in g^{-1}(y)}P\{X=x\}.$$

特别地, 如果 g 是单射函数, 则 $|\mathbb{X}| = |\mathbb{Y}|$ 且

$$\forall y \in \mathbb{Y}, \quad P\{Y = y\} = P\{X = g^{-1}(y)\}.$$

该方法可以推广到二元函数的情形: 已知离散型随机变量 X, Y 及其联合分布律, 则随机变量 $Z = g(X, Y)$ 的分布律为:

$$\forall z, \quad P\{Z = z\} = \sum_{(x,y):z=g(x,y)} P\{X = x, Y = y\}.$$

连续型随机变量的函数 已知连续型随机变量 X 的概率密度函数 f_X 和函数 g, 随机变量 $Y = g(X)$ 的概率密度函数 f_Y 按照如下步骤求得:

1. $F_Y(y) = P\{Y \le y\} = P\{g(X) \le y\} = \int_{x:g(x)\le y} f_X(x)\mathrm{d}x$;
2. $f_Y(y) = (F_Y(y))'$.

已知连续型随机变量 X 和 Y 及其联合概率密度函数 f 和函数 g, 随机变量 $Z = g(X, Y)$ 的概率密度函数 f_Z 按照如下步骤求得:

1. $F_Z(z) = P\{Z \le z\} = P\{g(X, Y) \le z\} = \displaystyle\int_{g(x,y)\le z} f(x, y)\mathrm{d}x\mathrm{d}y$;
2. $f_Z(z) = (F_Z(z))'$.

连续型随机变量的函数较难处理, 针对几个简单的函数, 我们给出直接求出概率密度函数的定理: 单调一元函数、四则运算.

单调一元函数 针对严格单调函数 g, 我们有如下的定理: 设随机变量 X 具有概率密度 $f_X(x), -\infty < x < \infty$, 且

- 函数 $g(x)$ 处处可导;
- 恒有 $g'(x) > 0$(或 $g'(x) < 0$); 记 $h(y)$ 为 $g(x)$ 的反函数;

则 $Y = g(X)$ 是连续型随机变量, 其概率密度为

$$f_Y(y) = \begin{cases} f_X(h(y))|h'(y)| & \alpha < y < \beta \\ 0 & \text{o.w.} \end{cases}$$

其中 $\alpha = \min\{g(-\infty), g(\infty)\}$, $\beta = \max\{g(-\infty), g(\infty)\}$. 该定理也可以改写为针对有限区间 $[\alpha, \beta]$, 此时要求 g 在区间 $[\alpha, \beta]$ 上满足要求即可.

和的分布 设 (X,Y) 是二维连续型随机变量, 其概率密度为 $f(x,y)$, 则 $X+Y$ 也是连续型随机变量, 其概率密度为

$$f_{X+Y}(z)=\int_{-\infty}^{\infty}f(z-y,y)\mathrm{d}y=\int_{-\infty}^{\infty}f(x,z-x)\mathrm{d}x$$

若 X 和 Y 相互独立, 则

$$f_{X+Y}(z)=\int_{-\infty}^{\infty}f_X(z-y)f_Y(y)\mathrm{d}y=\int_{-\infty}^{\infty}f_X(x)f_Y(z-x)\mathrm{d}x$$

这两个公式称为 f_X 和 f_Y 的<u>卷积公式</u>, 记作 f_X*f_Y.

差的分布 设 (X,Y) 是二维连续型随机变量, 其概率密度为 $f(x,y)$, 则 $X-Y$ 也是连续型随机变量, 其概率密度为

$$f_{X-Y}(z)=\int_{-\infty}^{\infty}f(z+y,y)\mathrm{d}y=\int_{-\infty}^{\infty}f(x,z+x)\mathrm{d}x$$

商和积的分布 设 (X,Y) 是二维连续型随机变量, 其概率密度为 $f(x,y)$, 则 $\dfrac{Y}{X}$ 和 XY 仍为连续型随机变量, 其概率密度为

$$\begin{aligned}f_{Y/X}(z)&=\int_{-\infty}^{\infty}|x|f(x,xz)\mathrm{d}x\\ f_{XY}(z)&=\int_{-\infty}^{\infty}\frac{1}{|x|}f(x,z/x)\mathrm{d}x=\int_{-\infty}^{\infty}\frac{1}{|y|}f(z/y,y)\mathrm{d}y.\end{aligned}$$

若 X 和 Y 相互独立, 则

$$\begin{aligned}f_{Y/X}(z)&=\int_{-\infty}^{\infty}|x|f_X(x)f_Y(xz)\mathrm{d}x,\\ f_{XY}(z)&=\int_{-\infty}^{\infty}\frac{1}{|x|}f_X(x)f_Y(z/x)\mathrm{d}x=\int_{-\infty}^{\infty}\frac{1}{|y|}f_X(z/y)f_Y(y)\mathrm{d}y\end{aligned}$$

极值分布 设随机变量 X 和 Y 互相独立, 其分布函数分别为 $F_X(x)$ 和 $F_Y(y)$; 由于

$$\begin{aligned}P\{\max\{X,Y\}\le z\}&=P\{X\le z,Y\le z\}=P\{X\le z\}P\{Y\le z\},\\ P\{\min\{X,Y\}\le z\}&=1-(1-P\{X\le z\})(1-P\{Y\le z\}),\quad\forall z\end{aligned}$$

故

$$F_{\max}(z)=F_X(z)F_Y(z),\qquad F_{\min}(z)=1-(1-F_X(z))(1-F_Y(z)).$$

上述讨论可以推广到 n 个独立的随机变量: 设 $X_1,\dots,X_n$ 是 n 个互相独立的随机变量, 其分布函数为 $F_i(x_i), i=1,\dots,n$, 则 $\max\{X_1,\dots,X_n\}$ 和 $\min\{X_1,\dots,X_n\}$ 的分布函数分别为

$$F_{\max}(z)=\prod_{i=1}^{n}F_i(z),\quad F_{\min}(z)=1-\prod_{i=1}^{n}(1-F_i(z)).$$

进一步, 如果 $X_1,\dots,X_n$ 独立同分布, 即 $F_1=\cdots=F_n=F$, 则

$$F_{\max}(z)=(F(z))^n,\quad F_{\min}(z)=1-(1-F(z))^n.$$

3 随机变量的数字特征

3.1 数学期望

定义 设离散型随机变量 X 的分布律为 $P\{X=x_i\}=p_i$, 若级数绝对收敛, 定义随机变量 X 的数学期望 (简称期望, 均值):

$$\mathbb{E}(X)=\sum_{i=1}^{\infty}x_ip_i.$$

数学期望 $\mathbb{E}(X)$ 由随机变量 X 完全确定. 设连续型随机变量 X 的概率密度为 $f(x)$, 若积分绝对收敛, 定义随机变量 X 的数学期望:

$$\mathbb{E}(X)=\int_{-\infty}^{\infty}xf(x)\mathrm{d}x$$

如果 X 服从某一分布, 也称 $\mathbb{E}(X)$ 是这一分布的数学期望. 注意, 数学期望不一定存在 (反例: 柯西分布).

变量函数的数学期望: 一元函数的情形 由于数学期望不包含随机变量的所有信息, 所以随机变量的函数的数学期望并不需要求出变量函数的分布. 设随机变量 Y 是随机变量 X 的函数: $Y=g(X)$, 其中 g 是连续函数.

- 如果 X 是离散型随机变量, 其分布律为 $P\{X=x_k\}=p_k$, 若级数绝对收敛, 则
$$\mathbb{E}(Y)=\mathbb{E}(g(X))=\sum_{k=1}^{\infty}g(x_k)p_k;$$
- 如果 X 是连续型随机变量, 其概率密度为 $f(x)$, 若积分绝对收敛, 则
$$\mathbb{E}(Y)=\mathbb{E}(g(X))=\int_{-\infty}^{\infty}g(x)f(x)\mathrm{d}x.$$

变量函数的数学期望: 二元函数的情形 设随机变量 Z 是随机变量 X,Y 的函数: $Z=g(X,Y)$, 其中 g 是连续函数.

- 如果 (X,Y) 是离散型随机变量, 其分布律为 $P\{X=x_i,Y=y_j\}=p_{ij}$, 若级数绝对收敛, 则
$$\mathbb{E}(Z)=\mathbb{E}(g(X,Y))=\sum_{i=1}^{\infty}\sum_{j=1}^{\infty}g(x_i,y_j)p_{ij}$$

- 如果 (X,Y) 是连续型随机变量, 其概率密度为 $f(x,y)$, 若积分绝对收敛, 则

$$\mathbb{E}(Z)=\mathbb{E}(g(X,Y))=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty}g(x,y)f(x,y)\mathrm{d}x\mathrm{d}y$$

数学期望的性质 利用数学期望的定义和函数期望, 可以证明数学期望具有如下的性质: 令 X,Y 是随机变量, a,b,c 是常数, 下面的期望都存在, 则

(1) $\mathbb{E}(c)=c$, $\qquad X\in[a,b]\implies\mathbb{E}(X)\in[a,b]$

(2) $\mathbb{E}(aX+bY)=a\mathbb{E}(X)+b\mathbb{E}(Y)$; $\qquad \mathbb{E}(cX)=c\mathbb{E}(X),\quad \mathbb{E}(X+Y)=\mathbb{E}(X)+\mathbb{E}(Y)$

进一步, 若随机变量 X,Y 互相独立, 则

$$(3)\ \mathbb{E}(XY)=\mathbb{E}(X)\mathbb{E}(Y).$$

3.2 方差

定义 设 X 是随机变量, 若 $\mathbb{E}((X-\mathbb{E}(X))^2)$ 存在, 则称其为 X 的<u>方差</u>, 记作 $\mathbb{D}(X)$ 或者 $\mathrm{Var}(X)$. 再定义 $\sigma(X)=\sqrt{\mathbb{D}(X)}$ 为<u>标准差</u> 或者<u>均方差</u>. 直观来讲, 若 $\mathbb{D}(X)$ 较小, 则 X 的取值更集中在 $\mathbb{E}(X)$ 附近; 反之, 则 X 取值较为分散. 因此, $\mathbb{D}(X)$ 是刻画 X 取值分散程度的一个量.

方差和期望 1 设随机变量 X 的期望和方差存在, 利用期望的性质和方差的定义, 有

$$\mathbb{D}(X)=\mathbb{E}(X^2)-\mathbb{E}(X)^2\quad 或者\quad \mathbb{E}(X^2)=\mathbb{E}(X)^2+\mathbb{D}(X).$$

这说明 $\mathbb{E}(X)$ 和 $\mathbb{D}(X)$ 给出了 X^2 的统计信息 (期望).

方差和期望 2 $\mathbb{D}(X)$ 是随机变量的函数 $g(X)=(X-\mathbb{E}(X))^2$ 的期望, 我们可以使用变量函数的期望公式计算 $\mathbb{D}(X)$:

- 若 X 是离散型随机变量, 其分布律为 $P\{X=x_k\}=p_k$, 则

$$\mathbb{D}(X)=\sum_{k=1}^{\infty}(x_k-\mathbb{E}(X))^2p_k;$$

- 若 X 是连续型随机变量, 其概率密度为 $f(x)$, 则

$$\mathbb{D}(X)=\int_{-\infty}^{\infty}(x-\mathbb{E}(X))^2f(x)\mathrm{d}x.$$

性质 方差有如下几个基础的性质: 设 X 是随机变量, c 是常数

(1) $\mathbb{D}(X) \geq 0, \quad \mathbb{D}(c) = 0, \quad \mathbb{D}(X) = 0 \Longleftrightarrow P\{X = \mathbb{E}(X)\} = 1.$

(2) $\mathbb{D}(cX) = c^2\mathbb{D}(X)$

(3) $\mathbb{D}(X+Y) = \mathbb{D}(X) + \mathbb{D}(Y) + 2\mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y))), \quad D(X+c) = D(X)$

若 X, Y 相互独立, 则

$$(3') \ \mathbb{D}(X+Y) = \mathbb{D}(X) + \mathbb{D}(Y).$$

上述性质可以推广到任意有限多个相互独立的随机变量之和的情况.

标准化变量 设 X 是随机变量, 定义 X 的<u>标准化变量</u> 为:

$$Y = \frac{X - \mathbb{E}(X)}{\sqrt{\mathbb{D}(X)}}$$

由期望和方差的性质可知: $\mathbb{E}(Y) = 0, \mathbb{D}(Y) = 1$.

马尔可夫不等式 设 X 是非负随机变量, 其数学期望存在, 则对任意 $a > 0$, 有

$$P\{X \geq a\} \leq \frac{\mathbb{E}(X)}{a}.$$

在已知期望的条件下, 我们可以估计概率 $P\{X < \epsilon\}$ 的下界:

$$P\{X < m\mathbb{E}(X)\} \geq 1 - \frac{1}{m}.$$

切比雪夫不等式 设 X 是随机变量, 其数学期望和方差存在, 则对任意 $\epsilon > 0$, 有

$$P\{|X - \mathbb{E}(X)| \geq \epsilon\} \leq \frac{\mathbb{D}(X)}{\epsilon^2}.$$

在已知期望和方差的条件下, 我们可以估计概率 $P\{|X - \mathbb{E}(X)| < \epsilon\}$ 的下界:

$$P\{|X - \mathbb{E}(X)| < m\sqrt{\mathbb{D}(X)}\} \geq 1 - \frac{1}{m^2};$$

3.3 协方差

定义 我们定义随机变量 X 与 Y 的<u>协方差</u> 为

$$\mathsf{Cov}(X, Y) = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y))) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y).$$

利用协方差, 我们可以重写变量和的方差:

$$\mathbb{D}(X+Y) = \mathbb{D}(X) + \mathbb{D}(Y) + 2\mathsf{Cov}(X, Y)$$

性质 根据定义, 我们可以推导出协方差的性质: 设 X, Y, Z 是随机变量, a, b 是常数, 有

$$
\begin{aligned}
&(1)\ \mathsf{Cov}(X,Y) = \mathsf{Cov}(Y,X) \\
&(2)\ \mathsf{Cov}(X,X) = \mathbb{D}(X) \\
&(3)\ \mathsf{Cov}(aX,bY) = ab\mathsf{Cov}(X,Y) \\
&(4)\ \mathsf{Cov}(X+Y,Z) = \mathsf{Cov}(X,Z) + \mathsf{Cov}(Y,Z)
\end{aligned}
$$

相关系数 协方差刻画了随机变量 X 和 Y 的关联性:

- 当 $\mathsf{Cov}(X,Y) > 0$ 时, X 与 Y 正相关;
- 当 $\mathsf{Cov}(X,Y) < 0$ 时, X 与 Y 负相关;
- 当 $\mathsf{Cov}(X,Y) = 0$ 时, X 与 Y 不相关;

但是不够精细. 我们在此基础上定义随机变量 X 与 Y 的<u>相关系数</u>为

$$\rho_{XY} = \frac{\mathsf{Cov}(X,Y)}{\sqrt{\mathbb{D}(X)}\sqrt{\mathbb{D}(Y)}}$$

若 $\rho_{XY} = 0$, 则称 X 和 Y<u>(线性) 不相关</u>. 它有如下的性质:

- $|\rho_{XY}| \le 1$;
- $|\rho_{XY}| = 1 \Longleftrightarrow \exists a, b \in \mathbb{R}, P\{Y = a + bX\} = 1$.

它可以用来表征 X, Y 之间线性关系紧密程度:

- 当 $|\rho_{XY}|$ 越大, X, Y 线性相关的程度越好; 当达到最大值 1 时, 两者具有线性关系;
- 当 $|\rho_{XY}|$ 越小, X, Y 线性相关的程度越差; 当达到最小值 0 时, 两者无线性相关性.

注意: ρ_{XY} 是无量纲的量.

不相关与独立 我们可以证明: 若 X 和 Y 独立, 则 X 和 Y 不相关; 反之不然. 相关性关心的是两个向量是否具有线性关系; 然而, 不线性相关不代表完全无关, 即独立. 当然, 根据逆否命题的性质, 如果 $\mathsf{Cov}(X,Y) \ne 0$, 两者必然相关, 则一定不独立.

3.4 矩

矩: 期望、方差、协方差的推广 设 X 和 Y 是随机变量且以下的数字特征存在, 则定义

- X 的 k 阶原点矩, 或者 k 阶矩: $\mathbb{E}(X^k)$, $k = 1, 2, \ldots$;

- X 的 k 阶中心矩: $\mathbb{E}((X-\mathbb{E}(X))^k)$, $k=1,2,\ldots$;
- X 和 Y 的 $k+\ell$ 阶混合矩: $\mathbb{E}(X^kY^\ell)$, $k,\ell=1,2,\ldots$;
- X 和 Y 的 $k+\ell$ 阶混合中心矩: $\mathbb{E}((X-\mathbb{E}(X))^k(Y-\mathbb{E}(Y))^\ell)$, $k,\ell=1,2,\ldots$.

我们可以看到:

- X 的期望 $\mathbb{E}(X)$ 是一阶原点矩;
- X 的方差 $\mathbb{D}(X)$ 是二阶中心矩;
- X,Y 的协方差 $\mathsf{Cov}(X,Y)$ 是二阶混合中心矩.

协方差矩阵 设 $n\geq 2$ 维随机变量 $(X_1,X_2,\ldots,X_n)$ 的二阶混合中心矩存在, 记

$$c_{ij}=\mathbb{E}((X_i-\mathbb{E}(X_i))(X_j-\mathbb{E}(X_j))),\quad i,j=1,2,\ldots,n$$

我们称 $\mathbf{C}=(c_{ij})_{i,j}$ 为随机变量 $(X_1,X_2,\ldots,X_n)$ 的<u>协方差矩阵</u>. 本课程中, 协方差矩阵主要用于研究高维正态分布.

4 重要分布

4.1 均匀分布

一维均匀分布 若连续型随机变量 X 具有概率密度

$$f(x)=\begin{cases}\dfrac{1}{b-a} & a<x<b\\ 0 & \text{o.w.}\end{cases}$$

则称 X 在区间 (a,b) 上服从<u>均匀分布</u>, 记作 $X\sim U(a,b)$. 均匀分布 $U(a,b)$ 描述了某种<u>等可能性</u>: X 落在区间 (a,b) 中子区间的概率只依赖于子区间长度, 与位置无关.

二维均匀分布 设 $D\subset\mathbb{R}^2$ 为有界区域, 其面积为 A, 如果随机变量 (X,Y) 的概率密度为

$$f(x,y)=\begin{cases}\dfrac{1}{A} & (x,y)\in D\\ 0 & \text{o.w.}\end{cases}$$

则称 (X,Y) 服从区域 D 上的<u>均匀分布</u>, 记作 $(X,Y)\sim U(D)$. 二维随机变量落在 D 内子区域的概率只依赖于子区域的面积, 与子区域的形状和位置无关. 二维均匀分布对应几何概型.

4.2 伯努利实验相关分布

二项分布和伯努利分布 若随机变量 X 的可能取值为 $0,1,2,\ldots,n$, 且分布率为

$$P\{X=k\}=C_n^k p^k(1-p)^{n-k},\quad k=0,1,\ldots,n,\quad 0<p<1,$$

则称 X 服从参数为 n,p 的二项分布, 记作 $X\sim B(n,p)$. 当 $n=1$, 我们称其为参数为 p 的伯努利分布.

几何分布 若随机变量 X 的可能取值为 $1,2,\ldots$ 且分布率为

$$P\{X=k\}=(1-p)^{k-1}p,\quad k=1,2,\ldots,\quad 0<p<1,$$

则称 X 服从参数为 p 的几何分布, 记作 $X\sim G(p)$.

背景: 伯努利实验 设试验 E 的可能结果为: A 及 $\overline{A}$, 则称 E 为伯努利试验. 令

$$P(A)=p,\quad P(\overline{A})=1-p$$

将伯努利试验独立重复进行 n 次, 则称这一串试验为 n 重伯努利试验.

- 设 X 表示在 n 重伯努利试验中事件 A 发生的次数, 则 $X\sim B(n,p)$.
- 设 Y 表示在多重伯努利试验中事件 A 首次发生时的试验次数, 则 $Y\sim G(p)$.

二项分布的形态 设 $X\sim B(n,p)$, 则 $P\{X=k\}$ 先是随着 k 的增大而增大, 达到最大值后再随着 k 的增大而减少. 使得 $P\{X=k\}$ 取到最大值的 k_0 称为该二项分布的最大可能次数:

- 若 $p(n+1)\notin\mathbb{Z}$, $k_0=\lfloor p(n+1)\rfloor$, 即小于 $p(n+1)$ 的最大的整数;
- 若 $p(n+1)\in\mathbb{Z}$, $k_0=p(n+1),p(n+1)-1$.

二项分布的可加性 若 $X\sim B(n,p)$ 和 $Y\sim B(m,p)$ 相互独立, 则 $X+Y\sim B(n+m,p)$.

4.3 泊松分布

定义 若随机变量 X 的可能取值为 $0,1,2,\ldots$ 且分布率为

$$P\{X=k\}=\frac{\lambda^k e^{-\lambda}}{k!},\quad k=0,1,\ldots,\quad \lambda>0,$$

则称 X 服从参数为 λ 的泊松分布, 记作 $X\sim\pi(\lambda)$.

背景 泊松分布是概率论中重要的分布之一. 自然界及工程技术中的许多随机指标都服从泊松分布. 在一定条件下, 下列随机变量都服从泊松分布: 电话总机在某一时间间隔内收到的呼叫次数; 某一时间间隔内来到某服务台要求服务的人数等.

泊松分布的可加性 设随机变量 $X \sim \pi(\lambda_1), Y \sim \pi(\lambda_2)$ 相互独立, 则 $X+Y \sim \pi(\lambda_1+\lambda_2)$.

泊松定理 设 $\lambda > 0$, $n = 1,2,\ldots$ 且 $np_n = \lambda$, 则对任意固定的 $k = 0,1,2,\ldots$, 有

$$\lim_{n\to\infty} C_n^k p_n^k (1-p_n)^{n-k} = \frac{\lambda^k e^{-\lambda}}{k!}$$

这表明: 当 n 很大而 p 很小 (因为定理中, np 为常数), 以 n,p 为参数的二项分布的概率值可以由参数为 $\lambda = np$ 的泊松分布的概率值近似:

$$C_n^k p^k (1-p)^{n-k} \approx \frac{\lambda^k e^{-\lambda}}{k!}.$$

近似能够简化计算过程 (当 n 很大时, 计算 $(1-p)^n$ 将变得复杂) 或者利用查表法 (见课本附录 3 泊松分布表); 当 $n \geq 20, p \leq 0.05$ 时, 近似效果颇佳.

4.4 正态分布

4.4.1 一维正态分布

背景和定义 正态分布是自然界及工程技术中最常见的分布之一. 如果一个随机指标受到诸多因素的影响, 但其中任何一个因素都不起决定性作用, 则该随机指标一定服从或近似服从正态分布. 若连续型随机变量 X 具有概率密度

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}, \quad -\infty < x < \infty$$

其中 $\mu, \sigma > 0$, 则称 X 服从参数为 μ, σ 的<u>正态分布</u>/<u>高斯分布</u>, 记作 $X \sim N(\mu, \sigma^2)$. 我们称 $N(0,1)$ 为<u>标准正态分布</u>, 其概率密度记为 φ, 概率分布函数记作 Φ. 正态分布相关的计算经常用到如下的结论:

$$\int_{-\infty}^{\infty} e^{-x^2/2} \mathrm{d}x = \sqrt{2\pi}.$$

参数和图像 我们可以证明

$$X \sim N(\mu, \sigma^2) \quad \Longrightarrow \quad \mathbb{E}(X) = \mu, \quad \mathbb{D}(X) = \sigma^2.$$

所以, 正态分布由其数学期望和方差唯一确定. 根据数学期望和方差的含义以及概率密度的解析式, 我们可以知道概率密度函数图像与参数的关系:

1. 关于 $x=\mu$ 对称, 且在此处取得最大值 $f(\mu)=\dfrac{1}{\sqrt{2\pi}\sigma}$;
2. x 离 μ 越远, $f(x)$ 越小; 对于同样长度的区间, 离 μ 越远, X 落在其中的概率越小.
3. 在 $x=\mu\pm\sigma$ 处有拐点, 以 x 轴为渐近线.
4. μ 决定位置: 固定 σ, 改变 μ, 图像沿着 x 轴平移, 而不改变形状.
5. σ 决定形状: 固定 μ, 改变 σ, 当 σ 越小, 图像越陡峭, X 落在 μ 附近的概率越大; 反之, 当 σ 越大, 图像越平坦, X 的取值越分散.

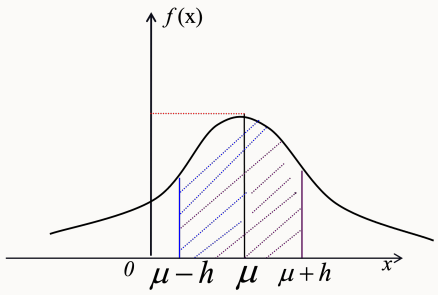

线性不变性 对任意常数 $a\neq 0$ 和 $b\in\mathbb{R}$, 我们有

$$X\sim N(\mu,\sigma^2) \quad\Longrightarrow\quad aX+b\sim N(a\mu+b,(a\sigma)^2).$$

分布函数 若 $X\sim N(0,1)$, 分布函数 $\Phi(x)$ 没有解析式, 但是

- 当 $x\geq 0$ 时, 查表法直接获得 $\Phi(x)$;
- 当 $x<0$ 时, 先利用查表法获得 $\Phi(|x|)$, 再利用对称性求解

$$\Phi(x)+\Phi(-x)=1.$$

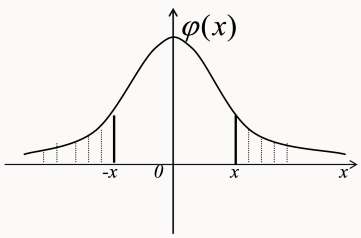

若 $X\sim N(\mu,\sigma^2)$, 则利用线性不变性

$$X\sim N(\mu,\sigma^2)\Longrightarrow\frac{X-\mu}{\sigma}\sim N(0,1).$$

将其转化为标准正态分布的情形:

$$F(x) = P\{X \le x\} = P\left\{\frac{X-\mu}{\sigma} \le \frac{x-\mu}{\sigma}\right\} = \Phi\left(\frac{x-\mu}{\sigma}\right).$$

分位点 分位点在数理统计中有广泛应用. 设 $X \sim N(0,1)$, 若 z_α 满足条件

$$P\{X > z_\alpha\} = \alpha, \quad 0 < \alpha < 1,$$

则称 z_α 为标准正态分布的上 α 分位点. 根据对称性可知, $z_{1-\alpha} = z_\alpha$. 分位点可查表获得.

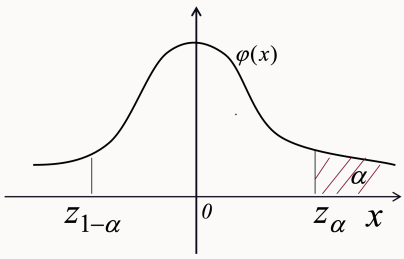

4.4.2 二维正态分布

定义 设随机变量 (X,Y) 的概率密度 $f(x,y)$ 为

$$\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left\{\frac{-1}{2(1-\rho^2)}\left(\frac{(x-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2}\right)\right\}$$

其中 $\sigma_1, \sigma_2 > 0$, $-1 < \rho < 1$, 则称 (X,Y) 服从参数为 $(\mu_1,\mu_2,\sigma_1,\sigma_2,\rho)$ 的二维正态分布, 记作 $(X,Y) \sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$.

性质 若 $(X,Y) \sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$, 则

- 边缘分布: $X \sim N(\mu_1,\sigma_1^2)$, $Y \sim N(\mu_2,\sigma_2^2)$;
- 条件分布: $Y_{|X=x} \sim N\left(\mu_2 + \rho\sigma_2\frac{x-\mu_1}{\sigma_1}, (1-\rho^2)\sigma_2^2\right)$;
- 独立性: $\rho = 0$ 当且仅当 X 与 Y 独立;
- 相关性: $\rho_{XY} = \rho$; 故, 对于二维正态分布来说, X,Y 相互独立等价于 X,Y 不相关.

正态分布的可加性 若 $(X,Y) \sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$ 而 a,b 为常数, 则

$$aX + bY \sim N(a\mu_1 + b\mu_2, a^2\sigma_1^2 + b^2\sigma_2^2 + 2ab\rho\sigma_1\sigma_2).$$

若 $X_1,\ldots,X_n$ 相互独立且 $X_i \sim N(\mu_i,\sigma_i^2)$, $i = 1,2,\ldots,n$, 又 $c_1,\ldots,c_n$ 为常数, 则

$$\sum_{i=1}^n c_iX_i \sim N\left(\sum_{i=1}^n c_i\mu_i, \sum_{i=1}^n c_i^2\sigma_i^2\right).$$

4.4.3 高维正态分布

定义 n 维正态随机变量 $(X_1, X_2, \ldots, X_n)$ 的概率密度函数为

$$f(x_1, x_2, \ldots, x_n) = \frac{1}{(2\pi)^{n/2}(\det \mathbf{C})^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^\top \mathbf{C}^{-1}(\mathbf{x}-\boldsymbol{\mu})\right\}$$

其中 $\boldsymbol{\mu} = (\mu_1, \mu_2, \ldots, \mu_n)$, $\mathbf{C}$ 是 $(X_1, X_2, \ldots, X_n)$ 的协方差矩阵.

性质 我们用 $(X_1, X_2, \ldots, X_n) \sim N(n)$ 表示 $(X_1, X_2, \ldots, X_n)$ 符合 n 维正态分布 (即, 我们只作定性描述, 忽略正态分布的参数). n 维正态分布具有如下性质:

1. 可组合性: 对任意的 $i = 1, 2, \ldots, n$, 有

$$(X_1, X_2, \ldots, X_n) \sim N(n) \quad \Longrightarrow \quad X_i \sim N(1);$$

   当 $X_1, X_2, \ldots, X_n$ 相互独立时, 有

$$X_i \sim N(1), \forall i = 1, 2, \ldots, n \quad \Longrightarrow \quad (X_1, X_2, \ldots, X_n) \sim N(n)$$

2. 线性性: 对不全为零的 $\ell_1, \ell_2, \ldots, \ell_n$, 有

$$(X_1, X_2, \ldots, X_n) \sim N(n) \quad \Longleftrightarrow \quad \ell_1 X_1 + \ell_2 X_2 + \cdots + \ell_n X_n \sim N(1);$$

3. 线性变换不变性: 对任意的 $\mathbf{L} \in \mathbb{R}^{n\times m}$, 有

$$(X_1, X_2, \ldots, X_n) \sim N(n) \quad \Longrightarrow \quad (X_1, X_2, \cdots, X_n)\mathbf{L} \sim N(m);$$

4. 若 $(X_1, X_2, \ldots, X_n) \sim N(n)$, 则它们相互独立等价于两两不相关.

4.5 Γ 分布、指数分布、χ^2 分布

预备: Γ 函数和 B 函数 Γ 函数定义如下

$$\Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x} \mathrm{d}x, \quad \alpha \in (0, +\infty)$$

性质如下:

$$\forall n \in \mathbb{N}, \Gamma(n) = (n-1)!, \quad \Gamma(\alpha+1) = \alpha\Gamma(\alpha), \quad \Gamma(1) = 1, \quad \Gamma(1/2) = \sqrt{\pi}.$$

B 函数定义如下:

$$B(\alpha, \beta) = \int_0^1 x^{\alpha-1}(1-x)^{\beta-1} \mathrm{d}x, \quad s > 0, t > 0$$

性质如下:

$$B(\alpha+1,\beta)=\frac{\alpha}{\alpha+\beta}B(\alpha,\beta),\quad B(\alpha,\beta+1)=\frac{\beta}{\alpha+\beta}B(\alpha,\beta)$$

B 函数和 Γ 函数存在如下的关系:

$$B(\alpha,\beta)=\frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$$

在计算中可以使用 Γ 函数和 Beta 函数及其性质简化计算, 当出现类似于它们定义的积分形式, 应该尽快使用 B 函数和 Γ 函数代替, 后续的计算也应该利用上述的性质.

Γ 分布 如果连续型随机变量 X 的密度函数为

$$f(x)=\begin{cases}\dfrac{\lambda^{\alpha}}{\Gamma(\alpha)}x^{\alpha-1}e^{-\lambda x} & x>0\\ 0 & \text{o.w.}\end{cases}$$

其中 $\alpha>0,\lambda>0$, 则称随机变量 X 服从参数为 (α,λ) 的 Γ 分布, 记作 $X\sim\Gamma(\alpha,\lambda)$. Γ 分布涵盖了很多重要的分布:

- 令 $\alpha=1$ 得到指数分布, 即 $E(\lambda)=\Gamma(1,\lambda)$;
- 令 $\alpha=n/2,\lambda=1/2$ 得到 χ^2 分布, 即 $\chi^2(n)=\Gamma(n/2,1/2)$, $n\geq 1$.

Γ 分布和 χ^2 分布的可加性. 若 $X_1,\ldots,X_n$ 相互独立, 则

$$X_i\sim\Gamma(\alpha_i,\lambda)\implies\sum_{i=1}^{n}X_i\sim\Gamma\left(\sum_{i=1}^{n}\alpha_i,\lambda\right).$$

因为 $\chi^2(n)=\Gamma(n/2,1/2)$, 上述定理立刻蕴含了 χ^2 分布的可加性: 若 X,Y 相互独立, 则

$$X\sim\chi^2(n),Y\sim\chi^2(m)\implies X+Y\sim\chi^2(m+n).$$

指数分布的无记忆性. 设 $X\sim E(\lambda)$, 对任意的 $x,\delta>0$, 有

$$P\{X>x+\delta|X>x\}=P\{X>\delta\}.$$

这被称为指数分布的无记忆性. 若排队时间服从指数分布, 已知已经等待 x 分钟的条件下, 再等待至少 t 分钟的条件概率, 与从开始起算等待至少 t 分钟的概率相同, 从什么时候开始等都是一样的.

4.6 常见分布的期望和方差

下表总结了常见分布的期望和方差.

	X	$\mathbb{E}(X)$	$\mathbb{D}(X)$		X	$\mathbb{E}(X)$	$\mathbb{D}(X)$
二项分布	$B(n,p)$	np	$np(1-p)$	均匀分布	$U(a,b)$	$(a+b)/2$	$(b-a)^2/12$
泊松分布	$\pi(\lambda)$	λ	λ	正态分布	$N(\mu,\sigma^2)$	μ	σ^2
几何分布	$G(p)$	$1/p$	$(1-p)/p^2$	Γ 分布	$\Gamma(\alpha,\lambda)$	α/λ	α/λ^2

5 概率论的理论基础

记号 设随机变量 $X_1, X_2, \ldots, X_n$, 定义

$$\overline{X}_n = \frac{X_1 + X_2 + \cdots + X_n}{n}, \qquad \widetilde{X}_n = X_1 + X_2 + \cdots + X_n.$$

5.1 大数定律

概率收敛 设 $Y_1, \ldots, Y_n, \ldots$ 是随机变量序列, A 是一个常数. 若对任意 $\epsilon > 0$, 有

$$\lim_{n\to\infty} P\{|Y_n - A| < \epsilon\} = 1 \quad \text{或者} \quad \lim_{n\to\infty} P\{|Y_n - A| \geq \epsilon\} = 0$$

则称 $Y_1, \ldots, Y_n, \ldots$ <u>依概率收敛于 A</u>, 记作 $Y_n \xrightarrow{P} A$. 若函数 $g(x,y)$ 在点 (a,b) 处连续, 则

$$X_n \xrightarrow{P} a,\ Y_n \xrightarrow{P} b \quad \Longrightarrow \quad g(X_n, Y_n) \xrightarrow{P} g(a,b).$$

切比雪夫大数定律 设 $X_1, \ldots, X_n, \ldots$ 相互独立, 且具有相同的数学期望 μ 和方差 σ^2, 则

$$\overline{X}_n \xrightarrow{P} \mu$$

此处 $X_1, X_2, \ldots$ 相互独立的含义是: 对任意的 $n > 1$, $X_1, \ldots, X_n$ 相互独立. 注意: 概率收敛考虑是随机变量序列 $\overline{X}_1, \ldots, \overline{X}_n, \ldots$.

伯努利大数定律可以更加弱, 我们不加证明地给出其弱化版本, 其中对方差没有要求.

辛钦大数定律 设随机变量 $X_1, \ldots, X_n, \ldots$, 相互独立同分布, 且数学期望为 μ, 则

$$\overline{X}_n \xrightarrow{P} \mu.$$

它比切比雪夫大数定律弱, 不要求方差存在, 故又称为弱大数定理, 具有更加广泛的应用.

伯努利大数定律、频率和概率的关系 设 $f_n(A)$ 为 n 重伯努利试验中事件 A 的频率, p 是该事件的概率, 则

$$f_n(A) \xrightarrow{P} p.$$

伯努利大数定律说明: 对任意小的正数 ϵ, 在 n 充分大时, 事件 "频率 $f_n(A)$ 与概率 p 的偏差超过 ϵ" 是小概率事件, 这是频率稳定性的严格数学描述. 根据实际推断原理, 当实验次数很大时, 便可用事件的频率来代替事件的概率.

5.2 中心极限定理

近似服从 设随机变量 $X_1,\ldots,X_n,\ldots$, 它们的分布函数为 $F_1,\ldots,F_n,\ldots$. 又设分布 $\mathscr{D}$ 具有分布函数 F. 若对任意的 $x\in\mathbb{R}$, 有

$$\lim_{n\to\infty} F_n(x) = F(x)$$

我们称当 n 趋向于无穷大时, X_n 服从 $\mathscr{D}$, 记作

$$n\to\infty, \quad X_n \sim \mathscr{D}.$$

分布 $\mathscr{D}$ 也可以取决于 n, 即分布的参数取决于 n.

独立同分布的中心极限定理 设随机变量 $X_1,X_2,\ldots,X_n,\ldots$ 相互独立且服从同一分布, 其数学期望和方差均为 μ 和 $\sigma^2>0$, 则

$$n\to\infty, \quad \widetilde{X}_n \sim N(n\mu, n\sigma^2) \quad \text{或者} \quad \frac{\widetilde{X}_n - n\mu}{\sqrt{n}\sigma} \sim N(0,1)$$
$$\overline{X}_n \sim N(\mu, \sigma^2/n) \quad \text{或者} \quad \frac{\overline{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0,1)$$

李雅普诺夫定理 设随机变量 $X_1,X_2,\ldots,X_n,\ldots$ 相互独立且服从同一分布, 其数学期望和方差均为

$$\mathbb{E}(X_k) = \mu_k, \quad \mathbb{D}(X_k) = \sigma_k^2 > 0, \quad \forall k = 1,2,\ldots$$

令 $B_n^2 = \sum_{k=1}^n \sigma_k^2$, 若存在正数 δ 使得

$$n\to\infty, \quad \frac{1}{B_n^{2+\delta}} \sum_{k=1}^n \mathbb{E}(|X_k-\mu_k|^{2+\delta}) \to 0$$

则

$$n\to\infty, \quad \widetilde{X}_n \sim N\left(\sum_{k=1}^n \mu_k, B_n^2\right) \quad \text{或者} \quad \frac{\widetilde{X}_n - \sum_{k=1}^n \mu_k}{B_n} \sim N(0,1).$$

德莫佛-拉普拉斯定理 设 $\eta_n \sim B(n,p)$, 则

$$n \to \infty, \qquad \eta_n \sim N(np, np(1-p)) \quad \text{或者} \quad \frac{\eta_n - np}{\sqrt{np(1-p)}} \sim N(0,1).$$

当 n 很大但 p 很小, 我们可以利用泊松定理将其近似为参数为 np 的泊松分布; 上面的定理说明, 若不考虑 p 的大小, 我们依然可以将其近似正态分布.

5.3 中心极限定理和大数定律

我们可以用中心极限定理估算“频率近似概率”的误差: 设 $\eta_n \sim B(n,p)$ 对应 n 重伯努利试验, 则其频率为 $f_n(A) = \eta_n / n$, 对任意 ϵ, 定义

$$\beta(p,n,\epsilon) = P\left\{\left|\frac{\eta_n}{n} - p\right| < \epsilon\right\}$$

它度量了 n 次试验所得频率的误差不超过 ϵ 的概率; 由德莫佛-拉普拉斯定理, η_n 近似服从正态分布 $N(np, np(1-p))$, 故当 $n \to \infty$, 有

$$\beta(p,n,\epsilon) = 2 \cdot \Phi\left(\epsilon\sqrt{\frac{n}{p(1-p)}}\right) - 1.$$